



小型微型计算机系统

Journal of Chinese Computer Systems

ISSN 1000-1220, CN 21-1106/TP

《小型微型计算机系统》网络首发论文

题目：生成对抗网络及其个性化推荐研究
作者：杨宇，吴国栋，刘玉良，汪菁瑶，范维成
收稿日期：2021-06-30
网络首发日期：2021-11-08
引用格式：杨宇，吴国栋，刘玉良，汪菁瑶，范维成. 生成对抗网络及其个性化推荐研究[J/OL]. 小型微型计算机系统.
<https://kns.cnki.net/kcms/detail/21.1106.TP.20211106.1215.004.html>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

生成对抗网络及其个性化推荐研究

杨宇, 吴国栋, 刘玉良, 汪菁瑶, 范维成

(安徽农业大学 信息与计算机学院, 合肥 230036)

E-mail: gdwu1120@qq.com

摘要: 生成对抗网络 (Generative Adversarial Nets) 是一种融合了生成学习和对抗学习的无监督学习方法, 以零和博弈作为核心思想, 其组件通过互相对抗不断地提升模型效果。将 GAN 模型融入到推荐领域中, 可有效缓解数据稀疏性问题, 提高推荐效果。本文从模型输入的是隐式反馈信息或显式反馈信息两个方面对基于 GAN 的个性化推荐模型进行了分析; 探讨了基于 GAN 的个性化推荐研究已取得的相关成果, 指出了现有 GAN 推荐研究在稳定性较差、优化难度大、模型复杂程度高等方面的不足; 并从缓解数据稀疏、融合图神经网络、解决数据离散性等方面对 GAN 推荐的未来发展性方向进行了展望。

关键词: 生成对抗网络; 推荐系统; 隐式反馈; 显式反馈

中图分类号: TP391 **文献标识码:** A

Research on Generative Adversarial Nets and Personalized Recommendation

YANG Yu, WU Guo-dong, LIU Yu-liang, WANG Jing-yao, FAN Wei-cheng

(School of Information and Computer, Anhui Agricultural University, Hefei 230036, China)

Abstract: Generative Adversarial Nets is an unsupervised learning method which integrates generative learning and adversarial learning. It takes zero-sum game as the core idea, and the model components constantly improve the model effect through mutual confrontation. Integrating GAN model into the field of recommendation can effectively alleviate the problem of data sparsity and improve the effect of recommendation. This paper discusses the research achievements of GAN in the field of recommendation, points out the shortcomings of GAN recommendation in the aspects of stability, optimization difficulty and model complexity, and looks forward to the future development direction of GAN recommendation from alleviating the problem of data sparsity, fusing graph neural network and solving the problem of data discreteness.

Key words: generative adversarial nets; recommend system; implicit feedback; explicit feedback

1 引言

随着信息技术的不断发展, 网络上的数据呈现了爆炸式增长, 人们难以从海量信息中提取自己需要的信息。为解决信息过载 (Information overload) 问题, 出现了个性化推荐技术, 其主要思想是帮助用户及时获取自己可能感兴趣的信息, 具有“千人千面”的特点。推荐系统不仅缓解了用户选择难的问题, 也可以通过对用户的行为、偏好等特征进行

分析, 发掘用户潜在的需求, 更好的为用户做推荐。推荐系统可以根据算法类型分为基于协同过滤的推荐系统和基于内容的推荐系统, 也可以根据模芯输入的数据类型分为显式和隐式反馈推荐系统^[1]。虽然推荐系统的研究取得了较大的成果, 但推荐系统仍然存在一些问题, 如数据稀疏性问题、冷启动问题、时效性问题、多样性推荐问题等^[2]。近年来, 生成对抗网络 (Generative Adversarial Nets, GAN)

收稿日期: 2021-06-30 收修改稿日期: 2021-07-26 基金项目: 国家自然科学基金项目(31671589)资助; 安徽省重点研发计划项目(201904a06020056)资助; 嵌入式系统与服务计算教育部重点实验室开放基金项目(ESSCKF2020-03)资助; 智慧农业技术与装备安徽省重点实验室开放基金项目(APKLSATE2019X003)资助。作者简介: 杨宇, 男, 1996年生, 硕士研究生, 研究方向为深度学习、推荐系统等; 吴国栋(通讯作者), 男, 1972年生, 博士, 副教授, CCF会员, 研究方向为深度学习、推荐系统和智能商务; 刘玉良, 男, 1997年生, 硕士研究生, 研究方向为深度学习、推荐系统等; 汪菁瑶, 女, 1997年生, 硕士研究生, 研究方向为深度学习、推荐系统等; 范维成, 男, 1997年生, 硕士研究生, 研究方向为深度学习、推荐系统等。

[3]因其可以生成足以以假乱真的虚假数据,有效填充真实数据集,被许多学者用于个性化推荐领域方面的研究。GAN 的核心是博弈论中的二人零和博弈思想,即参与博弈的二人,一人的收益必然意味着另一人的损失,且二人的收益与损失总和永远为“零”。由于原始 GAN 模型存在着训练困难、可控性较差、稳定性较差等问题[4],一些学者提出了 GAN 的变体,如条件生成对抗网络(Condition GAN, CGAN)[5]、信息生成对抗网络(InfoGAN)[6]、Wasserstein 生成对抗网络(Wasserstein GAN)[7]、带有梯度惩罚的 Wasserstein 生成对抗网络(Wasserstein GAN gradient penalty)[8]等。

本文在对 GAN 及其变体分析的基础上,根据模型所输入的是隐式反馈数据还是显式反馈数据的视角,对已有基于 GAN 的个性化推荐进行了探讨,并对当前基于 GAN 个性化推荐研究的不足和未来研究趋势进行了展望,以期对相关研究起到一定的借鉴作用。本文第 2 节对 GAN 及其常见变体进行了分析;第 3 节探讨了基于 GAN 和 CGAN 的推荐研究进展;第 4 节指出了 GAN 推荐存在的问题及不足;第 5 节展望了 GAN 推荐的未来研究方向;第 6 节对本文进行了总结。

2 生成对抗网络及其变体

2.1 原始 GAN 模型

原始 GAN 由两个部分组成,分别是生成器 G (Generator) 和判别器 D (Discriminator)。其中 G 负责捕获真实样本数据的分布,并尽可能生成与真实数据相像的虚假数据。 D 是一个二分类器,判断输入的样本数据来自真实数据分布的概率。GAN 的模型结构如图 1 所示。




图 1 GAN 结构图

Fig.1 Architecture of GAN

图 1 中 G 的目标是学习真实数据的分布 $P_{data}(x)$, 将随机变量 z (一般将 z 称为噪声) 输入到 G 之后, G 会生成一个与真实样本类似的虚假数据 $G(z)$, 其分布记为 $P_z(x)$ 。 D 的输入分为两个部分, 分别为虚假数据 $G(z)$ 和真实数据 x , D 的目标是判断输入的数据是 G 生成的虚假数据还是真实数据, 其

输出为一个概率值, 区间为 $0 \sim 1$, 越接近 0, 说明 D 认为该数据为虚假数据的概率越大; 越接近 1, 说明 D 认为该数据为真实数据的概率越大。在最优情况下, G 生成的虚假数据有着以假乱真的效果, 使得 D 完全无法分辨该数据究竟是 G 生成的虚假数据

还是真实数据, 即 $D(x) = \frac{P_{data}(x)}{P_{data}(x) + P_z(x)}$ 的值接近 0.5。

一般在这种情况下认为 G 已经训练到最优, 成功捕获并学到了真实数据的分布, 并且 G 和 D 达到了纳什均衡。

GAN 的整体优化目标实际上是一个极小化极大问题, 如公式(1)所示:

$$\min_G \max_D V(D, G) = (\mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + (\mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]) \quad (1)$$

GAN 每轮优化分为两步, 第一步固定 G , 即不对 G 的参数进行更新, 同时对 D 进行优化, 找到当前最优的判别器。对于公式(1), 此时 G 不再更新, 而 $D(x)$ 的输出结果的区间为 $[0, 1]$, 因此 $\log(D(x))$ 与 $\log(1 - D(G(z)))$ 的取值范围为 $(-\infty, 0]$, 为了使公式最大化, $D(x)$ 输出的值接近 1, $D(G(z))$ 输出的值接近 0, 这代表 D 成功识别了真实数据与虚假数据。第二步固定 D , 同时对 G 进行优化, 找到当前最优的生成器。此时公式(1)中 $\mathbb{E}_{x \sim p_{data}(x)} [\log D(x)]$ 不会进行更新, 只需关注公式中的另一项 $\mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$ 。在每轮优化中, 判别器的能力应该比生成器强一些, 但是又不能强太多, 因此一般来说, 判别器更新 K 次, 生成器才更新一次。 G 与 D 相互对抗博弈, 最终二者都达到最优状态。

2.2 CGAN 模型

对于原始 GAN, 生成过程没有受到任何约束, 导致生成的数据不可控[9]。为了约束生成过程, Mirza Mehdi 等人提出了条件生成对抗网络(Conditional Generative Adversarial Net, CGAN)。CGAN 与 GAN 的区别在于 G 和 D 的输入都额外增加了一个条件变量 y , y 可以是类别标签、描述文字、一张图片。CGAN 通过条件变量 y 来指导并约束生成过程, 使得 G 生成的结果可以拟合条件变量 y 。如果 y 是类别标签, 则可以把 CGAN 看作是无监督学习 GAN 模型向监督学习的改进[10]。CGAN 的结构如图 2 所示。

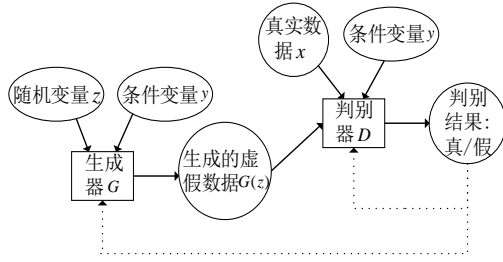


图2 CGAN 结构图

Fig.2 Architecture of CGAN

CGAN 的目标函数与 GAN 类似，只是在 G 和 D 的输入部分增加了条件变量 y ，目标函数的形式如公式(2)所示：

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x|y)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)|y))] \quad (2)$$

CGAN 的训练步骤也与 GAN 类似。在公式(2)中，虽然变量的输入部分 $G(z|y)$ 和 $D(x|y)$ 被写成了条件概率的形式，但在 CGAN 的具体实现中，只需要将 z 或 x 与 y 拼接起来即可。

2.3 其他 GAN 模型

与 CGAN 类似，Xi Chen 等人提出的 InfoGAN 也是为了解决 G 生成的数据不可控问题。作者认为 GAN 输入的噪声是混乱的，导致噪声的各个维度与真实数据的特征并不匹配。因此作者针对这种情况，将 G 的输入部分分为两个部分，一个部分仍为噪声 z ，另一个部分为代表真实数据不同特征的多个隐变量拼接而成的隐藏编码 c 。同时使用基于互信息的正则化约束项 $I(c; G(z, c))$ 用来约束隐藏编码 c 和生成的虚假样本 $G(z, c)$ 之间的相关程度。

Martin Arjovsky 等人^[11]证明了若将 GAN 训练

到最优情况，损失函数等价于最小化真实数据分布与生成数据分布的 JS 散度，且值为常数 $\log 2$ ，因此 GAN 模型优化的越好，梯度消失的情况越严重。针对这个问题，Martin Arjovsky 等人提出了 WGAN 模型，使用一种 Wasserstein 距离取代 GAN 中的 JS 散度计算方法。在试验中 WGAN 在训练的稳定性方面有着较好的表现，但仍然存在梯度爆炸或梯度消失的情况，并且生成的样本真实性较差。

针对 WGAN 存在着的梯度爆炸或梯度消失的问题，Ishaan Gulrajani 等人提出的 WGAN-GP 通过额外设置一个惩罚项以实现更好的效果。与 WGAN 相比，WGAN-GP 只在 WGAN 损失函数上增加了一个惩罚项。实验结果证明了 WGAN-GP 利用梯度惩罚拟合了较为复杂的函数，能够生成质量更高的数据，并且解决了梯度爆炸和梯度消失的问题。但是，因为惩罚项的计算成本较大，导致 WGAN-GP 的训练所需时间较长。

3 基于 GAN 的个性化推荐研究

通过对近年来基于 GAN 的个性化推荐的分析，常见的应用在推荐领域的 GAN 模型有原始 GAN 和改进后的 CGAN。GAN 的实现比较简单，往往不需要太复杂的设计就能达到较好的效果。CGAN 因为模型的输入额外加入了条件向量，生成的数据分布会更好拟合真实数据分布，因此在推荐领域中的表现较好。本节对基于 GAN 个性化推荐相关研究进行探讨分析。

表 1 总结了现有基于 GAN 的个性化推荐研究中相关模型的优缺点。

Table 1 Advantages and disadvantages of GAN personalized recommendation

表 1 GAN 个性化推荐的优缺点

GAN 推荐	类别	优点	缺点	模型名称	文献
基于 GAN 的个性化推荐	利用隐式反馈的 GAN 推荐	提高推荐效果	模型较为复杂、数据稀疏性问题	RecSimu	[12]
	利用显式反馈的 GAN 推荐	提高推荐效果、缓解冷启动问题	模型较为复杂、模型稳定性较差	CoFiGAN、CnGAN、RecSys-DAN、ColdGAN、RSGAN、GANMF	[19][22][25] [26][27][29]
	利用隐式反馈和显式反馈的 GAN 推荐	提高推荐效果	数据稀疏性问题	RecGAN、PURE	[30][35]
基于 CGAN 的个性化推荐	利用隐式反馈的 GAN 推荐	有较好的鲁棒性、提高推荐效果	模型较为复杂、模型稳定性较差、数据稀疏性问题	IRGAN、CFGAN、c*GAN、D2D-TM	[20][36][38] [40]
	利用显式反馈的 GAN 推荐	提高推荐效果	模型较为复杂、模型稳定性较差	GraphGAN、AR-CF、AugCF、PLASTIC	[37][48][49] [51]

3.1 原始 GAN 个性化推荐主要研究

3.1.1 基于隐式反馈的 RecSimu 推荐模型

Xiangyu Zhao 等人^[12]提出的 RecSimu 模型能

够模拟真实用户行为，可以预先训练和评估推荐算法。RecSimu 从用户的浏览记录中学得用户当前的偏好并推荐用户可能感兴趣的物品，然后预测用户

对推荐物品的反馈（如浏览、点击或购买等等）。

RecSimu 的结构如图 3 所示。

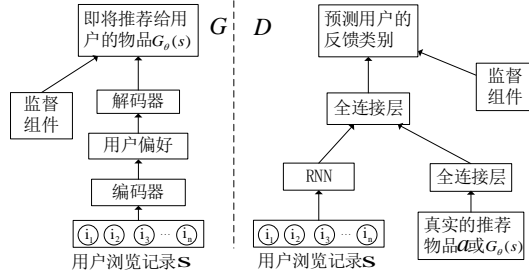


图 3 RecSimu 结构图

Fig.3 Architecture of RecSimu

如图 3 所示，左侧生成器 G 的输入为用户的历史浏览记录（包括用户浏览过的物品集合以及对每个物品的反馈），先使用编码器学习用户的偏好，再使用解码器和用户的当前偏好预测用户可能会喜欢的物品 $G_\theta(s)$ 。 G 额外加入了一个减少生成的推荐物品与真实的推荐物品之间差异的监督组件。图 3 右侧的判别器 D 的输入分为两部分，一部分为用户的历史浏览记录，另一部分为用户真实的推荐物品 a 或预测的推荐物品 $G_\theta(s)$ ，最终的输出为预测用户对推荐物品的反馈类别，共包括 K 个用户对真实推荐物品的反馈和 K 个用户对虚假推荐物品的反馈。 D 的目标不仅是区分推荐物品来自真实数据或生成数据，还要根据用户的浏览历史来预测用户对推荐物品的反馈类别。 D 同样额外加入了一个监督组件，监督组件的目标是减少用户的真实反馈与预测反馈所属类别的差异，以便能更好的预测用户对物品的反馈类别。

实验基于真实电子商务公司的数据，与 LR^[13]、GRU^[14]、GAN、GAN-s^[15] 等模型进行了对比试验，在 F1、MAP 等指标上有所提升，与 FM^[16]、W&D^[17]、GRU4REC^[18] 等模型比较了生成器的有效性，在 MAP、NDCG 等指标上提升了 5% 左右。实验结果证明了 G 所生成的推荐物品和 D 所预测的用户反馈都有着较好的效果，说明成功捕获了用户的潜在偏好。但模型本身较为复杂，没有考虑到多个反馈之间可能存在的依赖关系，而且在实际情况中，不同类型的反馈数量极不平衡，这也会对最终的推荐效果造成影响。

3.1.2 基于显式反馈的 CoFiGAN 推荐模型

Jixiong Liu 等人^[19]提出了 CoFiGAN，一种融合了 GAN 的协同过滤模型，其与应用在信息检索领域的 IRGAN^[20]类似，生成器 G 的目标是生成与真实数据相似的高质量数据，判别器 D 的目标是分辨真实数据与生成的虚假数据。不同的地方在于

IRGAN 选择间接向 G 分配奖励或惩罚信号进行优化，而 CoFiGAN 选择让 D 通过对 G 生成的虚假数据进行判断，生成正样本（ D 所认为会获得高奖励的样本）和负样本（ D 所认为会获得高惩罚的样本）来直接指导 G 的训练过程。CoFiGAN 的整体优化目标如公式 (3) 所示：

$$J^{\theta^*, \phi^*} = \min_{\theta} \max_{\phi} \sum_{u=1}^n (\mathbb{E}_{i \sim p_{true}} [\log D(i|u)] + \mathbb{E}_{d \sim p_{\theta}(i|u)} [\log(1 - D(i|u))]) \quad (3)$$

公式 (3) 中 $d \sim p_{\theta}(i|u)$ 代表用户 u 所采样物品的概率分布， p_{true} 代表用户 u 真实偏好的分布， $D(i|u)$ 的输出代表物品 i 属于用户 u 真实偏好分布的概率。

因为真实数据是离散的，无法使用梯度下降法对 G 进行优化，因此 CoFiGAN 使用了公式 (4) 对 G 进行优化：

$$\theta^* = \arg \min_{\theta} \sum_{u=1}^n (\mathbb{E}_{S^G \sim p_{\theta}(S|u)} [Dist(S^G, S^D)]) \quad (4)$$

公式 (4) 中 S^G 是指 G 生成的、在 G 看来会获得更高奖励的样本， S^D 是指 D 所认为会获得更高奖励的样本，距离函数 $Dist(S^G, S^D)$ 用来衡量 S^G 与 S^D 之间的差距。因此， G 为了获得更高的奖励，必须使得 $Dist(S^G, S^D)$ 的值最小，即 S^G 更像 S^D 。

实验基于 ML-100K、ML-1M、UserTag、NF5K5K 等数据集，采用准确率和 NDCG 作为评价指标，与 Neural-MF^[21]、IRGAN 等模型进行了比较。其中 CoFiGAN 在 NF5K5K 数据集上取得的效果最好，与 IRGAN 相比在两个指标上都提升了 30% 左右。

CoFiGAN 通过类似于强化学习的方式对模型进行优化，加快了收敛速度，增加了虚假数据的多样性，并且在一定程度上避免了模型崩溃，但模型复杂度较高，且没有缓解数据稀疏性问题。

3.1.3 基于显式反馈的 CnGAN 推荐模型

Dilruk Perera 等人^[22]等人针对跨领域推荐中非重叠用户无法获得较好推荐效果的情况提出了 CnGAN，该模型通过学习从目标网络到源网络的偏好流形映射，生成非重叠用户的源网络用户偏好，再将得到的用户偏好应用在目标网络上进行推荐。CnGAN 由生成任务和推荐任务两个部分组成。

生成任务由判别器 D 与生成器 G 组成。 G 的目标是学习一个映射函数，能够将非重叠用户在目标网络上的已知偏好映射为源网络上的缺失偏好。 D 的目标是判断输入的源网络与目标网络的偏好是否

是匹配对（匹配对是指在同一时间间隔内来自同一用户的源网络与目标网络的偏好）。

推荐任务的目标是利用非重叠用户在时刻 t 的目标网络偏好和 G 生成的源网络偏好,以及在时刻 t 之前用户与物品的交互情况,预测用户在时刻 $t+1$ 有可能交互的物品集合并进行推荐。推荐任务结构如图4所示。

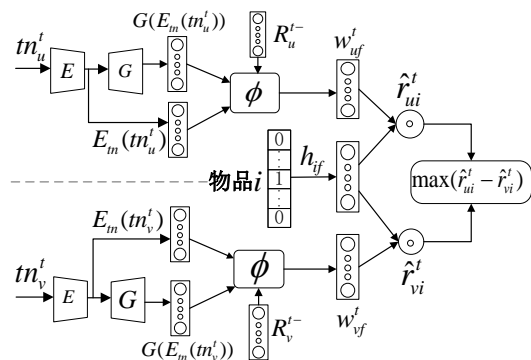


图 4 CnGAN 的推荐任务结构图

Fig.4 Recommender task architecture of CnGAN

将目标网络编码器处理过的用户 u 于时刻 t 在目标网络上的偏好 $E_{tn}(tn_u^t)$ 、 G 预测的经过编码的用户在源网络上的偏好 $G(E_{tn}(tn_u^t))$ 以及时刻 t 之前用户的偏好 R_u^t 输入到模型学到的转换函数 ϕ 中, 可以得到用户 u 的潜在表示 $w_{u,f}^t$ 。使用同样的方式可以得到用户 v 的潜在表示 $w_{v,f}^t$ 。然后分别将 $w_{u,f}^t$ 和 $w_{v,f}^t$ 分别与物品 i 的潜在表示 $h_{i,r}$ 进行内积, 结果为 用户 u 和 v 在时刻 t 对物品 i 的预测评分 \hat{r}_{ui}^t 和 \hat{r}_{vi}^t , 最终根据预测评分进行 Top-N 推荐。

CnGAN 选择 Twitter 数据集作为源网络, YouTube 数据集作为目标网络, 与 TBKNN^[23]、TDCN^[24]、CRGAN 等模型相比, 在命中率、NDCG 等指标上有着提升。

CnGAN 有效针对了非重叠用户推荐效果较差的问题，能够有效补充用户在源网络缺失的偏好，在 TOP-N 推荐中有着较好的表现，但是对于重叠用户的推荐效果没有达到预期。

3.1.4 基于显式反馈的其他推荐模型

同样是基于 GAN 的跨领域推荐模型, Cheng Wang 等人^[25]提出的 RecSys-DAN 用于解决跨领域中的数据稀疏和数据不平衡问题。通过训练源领域的生成器 G_s 用来初始化目标领域的生成器 G_t , 再训练评分函数用来判断 G_t 生成的用户、物品和交互行为与源领域的是否相似, 最终可以得到在目标领域推荐效果最好的用户集和物品集。

为了缓解冷启动问题, Po-Lin Lai 等人^[26]提出

了 ColdGAN。ColdGAN 使用一个基于时间的更新函数，用于将暖用户（评分过大量商品的用户）还原为冷用户（几乎没有评分过商品的用户）。用户对商品的评分越早，越有可能保留在还原之后的冷用户状态中。将还原后的冷用户输入到 ColdGAN 中，生成器 G 的目标是生成该冷用户对应的暖用户，判别器 D 的目标为判断输入的暖用户是否为真实的暖用户。

针对社会化推荐存在着大多数用户的朋友比较少以及用户的朋友不一定可靠的问题, Junliang Yu 等人^[27]提出了 RSGAN, 一种基于用户对他们可靠的朋友所消费的物品感兴趣的假设所设计的模型。RSGAN 通过生成用户的可靠朋友间接提高用户所获得的推荐效果。生成器 G 的目标是生成对该物品有着同样评分的可靠朋友, 并使用 Gumbel-Softmax 函数^[28]对可靠朋友消费的物品进行采样。判别器 D 判断用户对 G 输出的物品是否感兴趣, 并将其转为有序物品集合进行推荐。如果生成器 G 生成的可靠朋友没有提高推荐效果, D 将惩罚生成的可靠朋友并降低 G 生成此类朋友的概率。

Qingqin Wang 等人^[29]提出的 GANMF 首先构建了用户-物品矩阵, 利用用户对物品的评分历史, 使用基于图的混合协同过滤计算当前用户与其邻居节点的相似程度, 并从多阶邻居节点中获取更多的用户偏好, 构建包含用户信息的用户矩阵。使用同样的方式构建包含物品信息的物品矩阵。然后将用户矩阵作为 G 的输入, 物品矩阵作为 D 的输入, 并根据 G 预测的用户对物品的评分进行 Top-N 推荐。

3.1.5 基于隐式反馈和显式反馈的推荐模型

HomangaBharadhwaj 等人^[30]提出的 RecGAN 有效使用了 GRU, 模型目标是为了更好的利用用户和物品潜在特征的时间属性来提高推荐系统的有效性。为了更有效的模拟用户长短期行为和物品的潜在特征, 作者对 GRU 做了修改, 具体来说, 在更新门中引入了 ReLU 激活函数, 并在 GRU 模型中加入了协同技术。模型的整体优化公式如(5)所示:

$$\begin{aligned}
Q^* &= \min_{\text{Gen}} \max_{\text{Dis}} V(D, G) \\
&= \sum_{t=1}^T \sum_{i=1}^N \sum_{j=1}^M \mathbb{E}_{r \sim D(r|i, j)_{\text{real}|t}} [\log \text{Dis}(r|i, j, t)] + \\
&\quad \mathbb{E}_{r \sim D(r|i, j)_{\text{gen}|t}} [\log(1 - \text{Dis}(r|i, j, t))]
\end{aligned} \tag{5}$$

在公式(5)中, Gen 和 Dis 分别代表生成器和判别器, i 代表第 i 位用户, j 代表第 j 个物品, t 代表第 t 个时刻。 Gen 生成的用户 i 在时刻 t 对物品 j 的评分用 $(r|i, j, t)$ 表示, 学习到的用户偏好分布用 $D_{gen|t}$ 表示,

相应的, 用户真实的偏好分布用 $D_{real|t}$ 分布。

实验基于 Netflix Challenge、MyFitnessPal 等数据集, 与 RRN 相比, RecGAN 在 RMSE 指标上提升了 0.5%。与 PMF^[31]、T-SVD^[32]、AutoRec^[33] 等模型相比, RecGAN 在 MAP 指标上提升了大约 10%。RecGAN 并没有对修改后的 GRU 进行详细的测试, 无法判断修改后的 GRU 对模型带来的具体影响。

Zhou Yao 等人基于此文献^[34]的分析, 提出了一种名为 PURE^[35]的基于 GAN 的推荐模型。PURE 使用 PU 学习训练 D , G 学习用户和物品的潜在连续分布以生成高质量的用户和物品嵌入。通过与 PMF、GMF、CFGAN^[36] 等模型的比较, PURE 在精度、NDCG、MAP 等指标上都有着提升。

RecSimu、CoFiGAN、CnGAN、RSGAN、GANMF、RecGAN、PURE 等模型的主要目标是提高用户获得的推荐效果, RecSys-DAN 与 ColdGAN 的主要目标则是缓解冷启动问题, 不同的是 RecSys-DAN 针对的跨领域推荐的数据稀疏和数据不平衡问题, ColdGAN 针对的是普通用户遇到的冷启动问题。为了更好地捕获用户偏好, RecSimu、ColdGAN、RecSys-DAN、CnGAN、RecGAN 等模型都利用了用户的时间信息。考虑到数据的离散性, 每个模型选择的优化方式都有所不同, RSGAN 使用 Gumbel-Softmax 对模型进行优化, GANMF 使用策略梯度方法对模型进行优化, ColdGAN、RecSys-DAN、CnGAN、RecSimu、RecGAN、PURE、CoFiGAN 等根据模型自身特点使用了独特的优化方式, 如设计了独特的优化函数、直接指定正负样本等等。

3.2 CGAN 个性化推荐主要研究

3.2.1 基于隐式反馈的 IRGAN 推荐模型

Wang Jun 等人在 2018 年提出了一种用于信息检索领域的 IRGAN 模型。与 GAN 不同, IRGAN 中的生成器 G 的目标是从候选文档池中采样与查询相关的文档, 使采样的文档分布不断接近相关文档的真实分布。判别器 D 的目标是尽可能分辨出与该查询相关或不相关的文档。模型的整体优化目标如公式(6)所示:

$$J^{G^*, D^*} = \min_{\theta} \max_{\phi} \sum_{n=1}^N (\mathbb{E}_{d \sim p_{true}(d|q_n, r)} [\log D(d|q_n)] + \mathbb{E}_{d \sim p_{\theta}(d|q_n, r)} [\log(1 - D(d|q_n))]) \quad (6)$$

公式(6)中, q_n 是用户输入到信息检索模型里的查询, n 的取值范围是 $[1, N]$, d 是与 q_n 相关的文档, r 是 q_n 与 d 的相关程度。 $d \sim p_{true}(d|q_n, r)$ 为用户

提交查询的相关文档的分布, $p_{\theta}(d|q_n, r)$ 为 G 所学到的与用户提交查询的相关文档的分布。公式(7)展示了 D 的结构, 其中 $f_{\phi}(d_k, q_n)$ 为评分函数, 因此 D 输出的值为查询 q 与文档 d 相关的概率。

$$D(d|q) = \sigma(f_{\phi}(d, q)) = \frac{\exp(f_{\phi}(d, q))}{1 + \exp(f_{\phi}(d, q))} \quad (7)$$

因为文档是离散数据, 而随机梯度下降法 (Stochastic Gradient Descent) 是无法应用到离散数据中的, 因此 IRGAN 选择使用基于策略梯度 (Policy Gradient) 的强化学习 (Reinforcement Learning) 对模型进行优化。因此 G 的目标函数可以改写成公式(8):

$$\nabla_{\theta} J^G(q_n) = \frac{1}{K} \sum_{k=1}^K \nabla_{\theta} \log p_{\theta}(d_k|q_n, r) \log(1 + \exp(f_{\phi}(d_k, q_n))) \quad (8)$$

公式(8)中 $\log(1 + \exp(f_{\phi}(d_k, q_n)))$ 作为从 $p_{\theta}(d|q_n, r)$ 中选择文档 d 的奖励, d_k 代表从 G 生成 (或采样) 的文档中采样得到的第 k 个文档。为了减少强化学习过程中的差错, 将奖励项替换为对应的优势函数。

IRGAN 在网页搜索、问答系统和物品推荐这三个应用方向上做了实验, 不同的应用方向选择了不同的数据集, 分别为 LETOR、InsuranceQA、ML-100K 和 Netflix, 在不同的应用方向与多个模型做对比, IRGAN 取得了较好的效果。但是仍然存在着可解释性不足的问题, 并且在缺乏足够的用户反馈的情况下表现较差。

3.2.2 基于隐式反馈的 CFGAN 推荐模型

Dong-Kyu Chae 等人指出 IRGAN、GraphGAN^[37] 存在的问题, 即随着训练的进行, 相同的样本会被打上不同的标签: 当样本来自 G 时会被打上“假”标签, 当它来自于真实样本时会被打上“真”标签。因此 D 会退化, 无法更好的指导 G , 最终 G 与 D 的性能都会降低, 推荐精度也会下降。

为了解决这个问题, Dong-Kyu Chae 等人提出了一种基于 GAN 的协同过滤框架 CFGAN。CFGAN 中 G 的目标是生成与真实购买向量比较相似但绝对一样的购买向量, 而不是对用户可能感兴趣并将购买的物品进行采样, 这种方法有效防止了 G 生成的样本会被打上不同的标签。 D 的目标是区分生成的购买向量与用户真实的购买向量。

考虑到数据非常稀疏, 用户与物品有交互 (即购买) 时元素为 1, 否则为 0, 而 G 会倾向于不考虑用户偏好, 使生成的购买向量元素值全部为 1。为了解决这个问题, 作者提出了 3 种新的 CF 方

法:CFGAN_ZR、CFGAN_PM、CFGAN_ZP, 它们共同的核心思想是在每次训练中, 每个用户随机选择一部分从没有购买过的物品, 将其设置为负物品, 表示用户对该物品的购买向量值不是缺失的, 而是 0。然后 G 生成的用户购买向量中, 对应的负物品值接近 0。这样在 G 生成的购买向量中, 用户购买过的元素值接近 1, 没有购买过的值接近 0, 就可以避免 G 生成的购买向量的元素值全为 1。模型结构如图 5 所示。

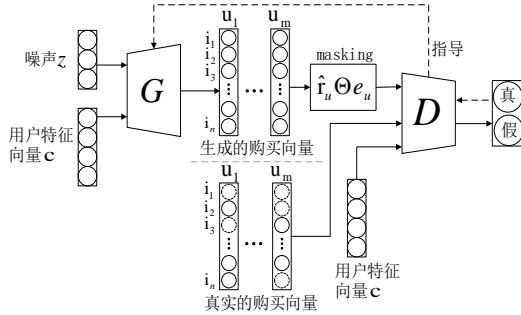


图 5 CFGAN 结构图

Fig.5 Architecture of CFGAN

图 5 中 z 是噪声, c 是用户特征向量, G 的输出是虚假的购买向量集 \hat{f}_u , 每一列代表一个用户, 共有 m 个用户, 每一行代表一个物品, 共有 n 个物品, 每个元素代表着用户对该物品的预测评分。 e_u 是 n 维向量, 若用户购买了物品, 则对应位置的元素值为 1, 否则为 0。 \hat{f}_u 与 e_u 进行哈达玛积是为了忽略用户没有购买的物品, 使 G 无法从被忽略的物品中得到损失梯度。对于真实的购买向量, 如果用户与物品之间有过购买行为, 则对应位置的元素值为 1, 否则为空 (不是 0)。 D 的输入为 \hat{f}_u 与 e_u 的哈达玛积、用户的真实购买向量与用户特征向量, 目标是判断购买向量的真假。

实验选择了 Ciao、Watcha、ML-100K、ML-1M 等数据集, 与 BPR、FISM、CDAE、IRGAN、GraphGAN 等模型进行对比, 实验结果显示 CFGAN 在准确率、召回率、NDCG、MRR 等评价指标上有着较好的表现, 在 TOP-N 推荐上有着较好的效果。但 CFGAN 在缺乏足够的用户交互的情况下表现较差, 并且模型的稳定性有待提高。

3.2.3 基于隐式反馈的其他推荐模型

Sudhir Kumar 等人^[38]提出的 c^+ GAN 的用于实际电商平台的服装推荐。对于任意服装图像都需要进行处理, 以去除模特图像, 并切割为上装和下装两个部分。为了更好的学习真实图像的分布, 基于 Sajjadi 等人^[39]的工作, 作者提出了一种新的随机标

签反转概念。 c^+ GAN 在必应商城中进行了应用, 推荐的结果无论是在图像质量还是在多样性上都有着较好的效果。

Linh Nguyen 等人^[40]提出的用于跨领域推荐的 D2D-TM 是 UNIT^[41]的扩展模型, 它既能提取不同领域间的同质特征, 也能提取不同领域间的差异特征。D2D-TM 由 CGAN、VAEs^[42]、Cycle-Consistency^[43]三个部分组成。生成器 G 由作为解码器的 VAEs 和作为解码器的 Cycle-Consistency 构成, 判别器 D 判断重构后的交互向量是否真实, 最终使用重构后的交互向量进行跨领域推荐。

3.2.4 基于显式反馈的 GraphGAN 推荐模型

Hongwei Wang 等人注意到了图神经网络中丰富的信息, 提出了一种图表示学习框架 GraphGAN。对于一个给定的结点 v_c , 生成器 $G(v|v_c; \theta_G)$ 的目标是拟合它的潜在真实连接分布 $p_{true}(v|v_c)$, 并生成 (或选择) 最有可能与 v_c 有连接的结点 v , 结点 v 形成的分布记为 $G(\cdot|v_c; \theta_G)$, D 的目标是判断生成的结点 v 与 v_c 之间是否存在连接, 并输出它们之间存在边的概率。整体优化目标如公式(9)所示:

$$\min_{\theta_G} \max_{\theta_D} V(D, G) = \sum_{c=1}^V (\mathbb{E}_{v \sim p_{true}(\cdot|v_c)} [\log D(v, v_c; \theta_D)] + \mathbb{E}_{v \sim G(\cdot|v_c; \theta_G)} [\log(1 - D(v, v_c; \theta_D))]) \quad (9)$$

公式(9)中 θ_G 和 θ_D 分别是结点 v 的 k 维表示向量的聚合。GraphGAN 使用的 softmax 函数有两个局限性, 首先 softmax 函数会计算图中所有的节点, 导致计算效率较低, 其次 softmax 函数没有利用图的结构信息。针对这些问题, 作者提出了 graph softmax 函数。graph softmax 函数具有能够生成有效的概率分布、利用图的结构信息、计算效率高等优点。具体而言, 从顶点 v_c 开始对图 G 进行广度优先搜索 (Breadth First Search, BFS), 最终形成了一棵以 v_c 为根节点的广度优先搜索树 T_c 。在 T_c 中任取一个节点 v , 其邻居 (直接与 v 连接的节点) 集合记为 $\mathcal{N}_c(v)$ 。节点 v 及其邻居 v_i 的相关概率计算公式如(10)所示:

$$p_c(v_i|v) = \frac{\exp(g_{v_i}^t g_v)}{\sum_{v_j \in \mathcal{N}_c(v)} \exp(g_{v_j}^t g_v)} \quad (10)$$

公式(10)中 g_{v_i} 和 g_{v_j} 代表对应节点的 k 维表示向量。对于 T_c 中任何一个节点来说, 都有一条唯一的路径可以从根节点 v_c 到达该节点。使用 graph softmax 函数定义的生成器 $G(v, v_c; \theta_G)$ 如公式(11)

所示:

$$G(v|v_c) \triangleq \left(\prod_{j=1}^m p_c(v_{r_j}|v_{r_{j-1}}) \right) p_c(v_{r_m}|v_{r_{m-1}}) \quad (11)$$

GraphGAN 创新性的通过生成对抗的思想去更新网络节点向量, 并且提出了 graph softmax 函数。实验基于 arXiv-AstroPh、arXiv-GrQc、BlogCatalog、Wikipedia、ML-1M 等数据集, 与 DeepWalk^[44]、Line^[45]、Node2Vec^[46]、Struc2vec^[47]等模型比较, 在 arXiv-AstroPh 和 arXiv-GrQc 数据集上的链接预测正确率分别提升了大约 3%和 10%, 在节点分类上的正确率提升了大约 11%和 20%。在推荐方向上与其他模型相比, 准确率提升了 38%到 156%不等。但是因为需要对每一个节点生成 BFS, 模型的时间复杂度和空间复杂度都比较高, 花费的代价较大。

3.2.5 基于显式反馈的其他推荐模型

针对冷启动和数据稀疏性问题, Dong-Kyu 等人^[48]提出了 AR-CF, 一种使用多个 CGAN 生成虚拟但可信的用户和物品, 将其作为附加信息来扩充评分矩阵的 CF 模型。通过在 ML-100K、Watcha、ML-1M、CiaoDVD 等数据集上的实验, 证明了确实一定程度上缓解了冷启动问题, 同时在推荐精度上也有所提高。但模型较为复杂, 对算力要求较高。

Wang 等人^[49]针对不活跃用户获得的推荐效果较差提出了 AugCF。AugCF 基于 DADA^[50]的标签系统将数据标签从两个(喜欢, 不喜欢)扩充到了四个(真实&喜欢, 真实&不喜欢, 虚假&喜欢, 虚假&不喜欢), 成功将数据扩充阶段与推荐阶段融合进模型中。在数据扩充阶段, D 作为二分类器判断数据是真实还是 G 生成的虚假数据。在推荐阶段, D 作为协同过滤模型判断用户是否会喜欢该物品。AugCF 在数据较为稀疏的情况下有着较好的表现。

Zhao Wei 等人^[51]提出的 PLASTIC 融合了矩阵分解和 RNN, 利用用户历史交互记录预测用户在某个时间可能会感兴趣的物品列表, 并进行 Top-N 推荐。

IRGAN 作为第一个应用在推荐领域的 GAN 模型, 为推荐领域的研究提供了新的方向, 尤其是开创性地使用策略梯度方法优化 GAN 推荐模型, 影响了后续很多基于 GAN 的个性化推荐模型。从应用方向上来看, AugCF 主要用于缓解数据稀疏性, 其它模型都可以应用在 TOP-N 推荐方向, 其中 IRGAN 可以应用在网页搜索、问答系统等方向,

GraphGAN 可以应用在链路预测、节点分类等方向, AR-CF 可以缓解冷启动。在优化方式上, IRGAN、CFGAN、GraphGAN、PLASTIC 等模型都是用了策略梯度方法对模型进行优化, 而 c⁺GAN、D2D-TM、AR-CF、AugCF 使用了其他方式对模型进行了优化。

4 已有 GAN 个性化推荐研究中存在的问题

GAN 推荐虽然在提升推荐精度、缓解数据稀疏性上有着较好的表现, 但在某些方面仍然存在着一些不足。

(1) 稳定性较差。基于 GAN 的推荐模型都存在着稳定性较差的问题, 因为需要小心协调生成器和判别器的训练程度。若是顾此失彼, 导致一方训练地较好, 而另一方训练地较差, 模型的推荐效果就会非常差。另外, 在训练过程中, 梯度很容易消失, 进而导致模型容易坍塌。随着训练的进行, 生成器会倾向于生成最简单的且永远不会犯错的数据, 导致生成的数据同质化严重, 且没有任何值得参考的价值。可以尝试使用经过优化后的 GAN 模型, 如 InfoGAN、WGAN-GP 等缓解这种现象。

(2) 缺少通用的优化方法。对于使用反向传播进行优化的 GAN 模型而言, 模型所需要的真实数据分布必须是连续的, 不能是离散的, 不然会导致无法使用梯度下降法对模型进行优化。对于离散数据, 基于 GAN 的个性化推荐模型虽然可以通过策略梯度方法、Gumbel-Softmax 函数等方式对模型进行优化, 但仍然缺少一个通用的优化方法。

(3) 模型较为复杂, 时空复杂度较高。GAN 本身的结构较为简单, 将其应用到推荐系统后, 要想达到较好的推荐效果, 往往需要与其他模型、函数进行融合。考虑到 GAN 本身存在的优化问题, 又需要使用其他的手段对模型进行优化, 最终模型变得较为复杂, 时空复杂度都较高。除了提高硬件水平之外, 也可以像 EBGAN^[52]那样, 可以通过预训练使模型的一部分先获得较强的能力, 降低时间复杂度对实际业务带来的影响。

(4) 缺少通用的评测指标。在推荐领域中, 可以通过 NDCG、精度、召回率等指标分析 GAN 推荐的效果, 但目前没有一个通用的评测 GAN 模型训练程度的评测指标, 或许可以通过计算生成样本与实际样本之间的相似系数来评估 GAN 模型训练的程度。

5 GAN 个性化推荐未来研究方向

随着互联网数据的急速增加和不断提高的无

监督学习的重要性,基于 GAN 的个性化推荐研究与应用越来越多。未来 GAN 推荐的主要研究方向:

(1) 提高模型稳定性。如何协调生成器 G 和判别器 D 之间的训练程度,提高 GAN 的稳定性一直是 GAN 模型所要解决的重要问题之一,提升 GAN 推荐的稳定性,避免模型出现难以训练、易坍塌的问题,仍是今后研究的一个重点。

(2) 缓解推荐过程中数据的稀疏问题。GAN 最大的优点在于能够生成虚假的数据,并且在极小化极大思想的指导下,生成的数据分布能够不断拟合真实数据分布,这能够很好的缓解数据稀疏性问题。目前已经有部分 GAN 推荐模型用于缓解数据稀疏问题、冷启动问题,但是总体而言针对数据稀疏问题的模型仍然较少。针对缓解数据稀疏问题的 GAN 推荐模型仍然需要研究。

(3) 多场景融合的 GAN 推荐。随着互联网的发展,需要推荐领域的不仅仅是电子商务平台,包括社交工具、视频平台、信息聚合平台等等各种平台。在不同的场景下,所能获取的数据类型也是不同,如视频、音频、社交关系、文本、时间序列等等,融合不同类型场景,结合上下文感知、社交关系、时间序列或多种数据进行推荐,也是 GAN 推荐的一个研究方向。

(4) 融入图神经网络的 GAN 推荐。图神经网络含有丰富的信息,包括用户-用户、用户-物品、物品-物品等等,除了节点本身的属性外,节点之间的边也可以表示多种信息,如购买历史、社会关系等等。若是 GAN 能够有效利用图神经网络里的信息,更好的提取图中的数据与关系,相信能够很好的提升推荐效果。虽然目前的研究较少,但此方向值得关注。

6 结束语

生成对抗网络自 2014 年被提出以来,在各个领域都受到了诸多关注。得益于 GAN 基于极小化极大的核心思想,GAN 在无监督学习上具有一定优势,最近几年,基于 GAN 的模型数量在快速提升。GAN 推荐因为所使用的模型、优化方法等等都不一样,在不同的领域有着不同的效果,在实际运用时需要根据所要针对的领域选取不同的 GAN 推荐模型,更好的利用其优势。本文从基于 GAN 的个性化推荐所使用的基础模型类别出发,针对当前 GAN 推荐的研究现状进行了分析,并探讨了各个模型的优缺点。针对 GAN 推荐存在的训练困难、模型易坍塌、优化问题、模型较为复杂等方面进行

了简单介绍,并对提高模型稳定性、着重缓解数据稀疏问题、融合多场景和融入图神经网络等方向对 GAN 个性化推荐的未来研究方向进行了展望。

References:

- [1] Li Kun-lun, Su Hua-ding, Rong Jing-yue. Personalized recommendation system incorporated with the implicit feedback of projects and users[J]. Journal of Chinese Computer Systems, 2020, 41(3): 519-525.
- [2] Yang Jin-ji, Hu Bo, Wang Xin-ming, et al. Personalized recommendation algorithm for earning to rank by knowledge graph[J]. Journal of Chinese Computer Systems, 2018, 39(11): 2419-2423.
- [3] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems(NIPS), 2014: 2672-2680.
- [4] Liang Jun-jie, Wei Jian-jing, Jiang Zheng-feng. Generative adversarial networks GAN overview[J]. Frontiers of Computer Science and Technology, 2020, 14(1): 1-17.
- [5] Mirza M, Osindero S. Conditional generative adversarial nets[EB/OL]. <https://arxiv.org/abs/1411.1784>, 2014.
- [6] Chen X, Duan Y, Houthoofd R, et al. InfoGAN: interpretable representation learning by information maximizing generative adversarial nets[C]//Proceedings of 30th International Conference on Neural Information Processing Systems(NIPS), 2016: 2180-2188.
- [7] Arjovsky M, Chintala S, Bottou L. Wasserstein GAN[C]//Proceedings of the 34th International Conference on Machine Learning(ICML), 2017: 214-223.
- [8] Gulrajani I, Ahmed F, Arjovsky M, et al. Improved training of wasserstein GANs[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems(NIPS), 2017: 5769-5779.
- [9] Gan Yan, Ye Mao, Zeng Fan-yu. Review of research on generative adversarial networks and

- its application[J].Journal of Chinese Computer Systems,2020,41(6):1133-1139.
- [10] Zhu Xiu-chang,Tang Gui-jin.A survey on generative adversarial networks in image processing[J].Nanjing University of Posts and Telecommunications,2019,39(3):1-12.
- [11] Arjovsky M,Bottou L.Towards principled methods for training generative adversarial networks[C]//Proceedings of the 5th International Conference on Learning Representations(ICLR),2017:1-17.
- [12] Zhao X Y,Xia L,Ding Z Y,et al.Toward simulating environments in reinforcement learning based recommendations[EB/OL].<https://arxiv.org/abs/1906.11462v2>,2019.
- [13] Menard S.Applied logistic regression analysis [M].Newbury Park:SAGE Publications,2001.
- [14] Cho K,Merriënboer B V,Gulcehre C,et al.Learning phrase representations using RNN encoder-decoder for statistical machine translation [EB/OL].<https://arxiv.org/abs/1406.1078>,2014.
- [15] Luc P,Couprie C,Chintala S,etal.Semantic segmentation using adversarial networks[EB/OL].<https://arxiv.org/abs/1611.08408>,2016.
- [16] Rendle S.Factorization machines[C]//Proceedings of the 10th IEEE International Conference on Data Mining(ICDM),2010:995-1000.
- [17] Cheng H T,Koc L,Harmsen J,et al.Wide & deep learning for recommender systems[C]//Proceedings of the 1st Workshop on Deep Learning for Recommender Systems(DLRS),2016: 7-10.
- [18] Hidasi B,Karatzoglou A,Baltrunas L,et al.Session-based recommendations with recurrent neural networks[EB/OL].<https://arxiv.org/abs/1511.06939>,2015.
- [19] Liu J X,Pan W K,Zhong M.CoFiGAN:collaborative filtering by generative and discriminative training for one-class recommendation[J].Knowledge-Based Systems,2019,191(6):105255.
- [20] Wang J,Yu L T,Zhang W N,et al.IRGAN:a minimax game for unifying generative and discriminative information retrieval models[C]//Proceedings of the 40th International ACM SIGIR Conference on Research and Development in Information Retrieval(SIGIR),2017:515-524.
- [21] He X N,Liao L Z,Zhang H W,et al.Neural collaborative filtering[C]//Proceedings of the 26th International Conference on World Wide Web(WWW),2017:173-182.
- [22] Dilruk P,Zimmermann R.CnGAN:generative adversarial networks for cross-network user preference generation for non-overlapped users [C]//World Wide Web Conference,2019:3144-3150.
- [23] Campos P G,Bellogin A,Diez F,et al.Simple time-biased KNN-based recommendations[C]//Proceedings of the Workshop on Context-Aware Movie Recommendation(CAMRa),2010:20-23.
- [24] Perera D,Zimmermann R.Exploring the use of time-dependent cross-network information for personalized recommendations[C]//Proceedings of the 25th ACM International Conference on Multimedia(MM),2017:1780-1788.
- [25] Wang C,Niepert M,Li H.RecSys-DAN:discriminative adversarial networks for cross-domain recommender systems[J].IEEE Transactions on Neural Networks and Learning Systems,2019,31(8):1-10.
- [26] Lai P L,Chen C Y,Lo L W,et al.ColdGAN:resolving cold start user recommendation by using generative adversarial networks[EB/OL].<https://arxiv.org/abs/2011.12566>,2020.
- [27] Yu J L,Gao M,Yin H Z,et al.Generating reliable friends via adversarial training to improve social recommendation[C]//Proceedings of the 19th IEEE International Conference on Data Mining(ICDM),2019:768-777.
- [28] Jang E,Gu S X,Poole B.Categorical reparameterization with gumbel-softmax[C]//Proceedings of the 5th International Conference on Learning Representations(ICLR),2017:1-12.
- [29] Wang Q Q,Xiong Y,Zhu Y.GAN-based deep matrix factorization for recommendation systems[C]//Proceedings of the 6th International Conference on Data Science(ICDS),2019:396-4

- [30] Bhargadhwaj H, Park H, Lim B Y. RecGAN: recurrent generative adversarial networks for recommendation systems[C]//Proceedings of the 12th ACM Conference on Recommender Systems, 2018: 372–376.
- [31] Mnih A, Salakhutdinov R R. Probabilistic matrix factorization[C]//Proceedings of the 20th International Conference on Neural Information Processing Systems (NIPS), 2007: 1257–1264.
- [32] Koren Y. Collaborative filtering with temporal dynamics[J]. Communication of the ACM (C ACM), 2010, 53(4): 89–97.
- [33] Ouyang Y X, Liu W Q, Rong W G, et al. Auto encoder-based collaborative filtering[C]//Proceedings of the 21st International Conference on Neural Information Processing (ICONIP), 2014: 284–291.
- [34] Kiryo R, Niu G, Plessis M, et al. Positive-unlabeled learning with non-negative risk estimator[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems (NIPS), 2017: 1674–1684.
- [35] Zhou Y, Xu J, Wu J, et al. GAN-based recommendation with positive-unlabeled sampling[EB/OL]. <https://arxiv.org/abs/2012.06901>, 2020.
- [36] Chae D K, Kang J S, Kim S W, et al. CFGAN: a generic collaborative filtering framework based on generative adversarial networks[C]//Proceedings of the 27th ACM International Conference on Information and Knowledge Management (CIKM), 2018: 137–146.
- [37] Wang H W, Wang J, Wang J L, et al. Graph GAN: graph representation learning with generative adversarial nets[C]//Proceedings of the 32nd AAAI Conference on Artificial Intelligence, 2018: 2508–2515.
- [38] Kumar S, Gupta M D. c⁺GAN: complementary fashion item recommendation[EB/OL]. <https://arxiv.org/abs/1906.05596>, 2019.
- [39] Sajjadi M S M, Parascandolo G, Mehrjou A, et al. Tempered adversarial networks[C]//Proceedings of the 35th International Conference on Machine Learning (ICML), 2018: 4448–4456.
- [40] Nguyen L, Ishigaki T. Domain-to-domain translation model for recommender system[EB/OL]. <https://arxiv.org/abs/1812.06229>, 2018.
- [41] Liu M Y, Breuel T, Kautz J. Unsupervised image-to-image translation networks[C]//Proceedings of the 31st Annual Conference on Neural Information Processing Systems (NIPS), 2017: 700–708.
- [42] Kingma D P P, Welling M. Auto-encoding variational Bayes[EB/OL]. <https://arxiv.org/abs/1312.6114>, 2014.
- [43] Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//IEEE International Conference on Computer Vision (ICCV), 2017: 2242–2251.
- [44] Perozzi B, Al-Rfou R, Skiena S. Deepwalk: online learning of social representations[C]//Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD), 2014: 701–710.
- [45] Tang J, Qu M, Wang M Z, et al. Line: large-scale information network embedding[C]//Proceedings of the 24th International Conference on World Wide Web (WWW), 2015: 1067–1077.
- [46] Grover A, Leskovec J. node2vec: scalable feature learning for networks[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD), 2016: 855–864.
- [47] Figueiredo D R, Ribeiro L F R, Saverese P H P. Struc2vec: learning node representations from structural identity[C]//Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD), 2017: 385–394.
- [48] Chae D K, Kim J, Chau D H, et al. AR-CF: augmenting virtual users and items in collaborative filtering for addressing cold-start problems[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR), 2020: 1251–1260.
- [49] Wang Q Y, Yin H Z, Wang H, et al. Enhancing

- collaborative filtering with generative augmentation[C]//Proceedings of the 25th ACM SIG KDD International Conference on Knowledge Discovery and Data Mining(KDD),2019:548-556.
- [50] Zhang X F,Wang Z Y,Liu D,et al.DADA:deep adversarial data augmentation for extremely low data regime classification[C]//Proceedings of the International Conference on Acoustics,Speech and Signal Processing,2019:2807-2811.
- [51] Zhao W,Wang B Y,Ye J B,et al.PLASTIC:priorityze long and short-term information in top-n recommendation using adversarial training[C]//Proceedings of the 27th International Joint Conference on Artificial Intelligence,2018:3676-3682.
- [52] Zhao J B,Mathieu M,LeCun Y.Energy-based generative adversarial network[EB/OL].<https://arxiv.org/abs/1609.03126>,2017.

附中文参考文献:

- [1] 李昆仑,苏华汀,戎静月.融合项目和用户隐式反馈的个性化推荐系统[J].小型微型计算机系统,2020,41(3):519-525.
- [2] 杨晋吉,胡波,王欣明,等.一种知识图谱的排序学习个性化推荐算法[J].小型微型计算机系统,2018,39(11):2419-2423.
- [4] 梁俊杰,韦舰晶,蒋正锋.生成对抗网络 GAN 综述[J].计算机科学与探索,2020,14(1):1-17
- [9] 淦艳,叶茂,曾凡玉.生成对抗网络及其应用研究综述[J].小型微型计算机系统,2020,41(6):1133-1139.
- [10] 朱秀昌,唐贵进.生成对抗网络图像处理综述[J].南京邮电大学学报(自然科学版),2019,39(3):1-12.