

《智能信息处理》课程考试

知识图谱在推荐系统中的应用

石现

考核	到课[10]	作业[20]	考试[70]	课程成绩[100]
得分				

2021 年 11 月 29 日

知识图谱在推荐系统中的应用

石现

(大连海事大学 信息科学技术学院, 大连 116026)

摘要 推荐系统的基本任务是联系用户和物品, 解决信息过载的问题, 帮助用户找到其感兴趣的内容。个性化的推荐系统更是可以为用户推荐专属的物品目录, 尽可能满足用户的个性化需求。但是推荐系统也面临一些挑战, 如数据稀疏和冷启动等问题。另一方面, 用知识图谱构建用户与物品, 或者物品与物品之间的信息可以作为一个外部知识来缓解上述问题, 并提高推荐系统的可解释性。基于此, 本文讨论了基于知识图谱的推荐系统未来可能的发展趋势。

关键词 推荐系统; 知识图谱; 发展趋势;

Application of knowledge graph in recommendation system

Shi Xian

(School of Information Science and Technology, Dalian Maritime University, Dalian 116026)

Abstract The basic task of recommendation system is to contact users and items, solve the problem of information overload, and help users find the content they are interested in. Personalized recommendation system can also recommend exclusive catalog for users, as far as possible to meet the personalized needs of users. However, the recommendation system also faces some challenges, such as data sparsity and cold start. On the other hand, using knowledge maps to construct information between users and items, or between items, can serve as external knowledge to alleviate the above problems and improve the interpretability of recommendation systems. Based on this, the future development trend of recommendation system based on knowledge graph is discussed in this paper.

Key words Recommendation system; Knowledge graph; Development trend;

1 引言

在信息爆炸的社会, 人们面对的信息量呈指数级增长。如何构建高效的推荐系统, 从海量信息中准确的挑选出对用户有价值, 用户感兴趣的信息成了一个至关重要的问题。当下, 推荐系统已经在电商, 社交平台, 个性化内容推荐等, 领域发挥了重要作用, 成了现代互联网应用场景中不可或缺的一部分。传统的推荐系统主要包括基于协同过滤的推荐系统, 基于内容的推荐系统, 以及混合推荐系统。协同过滤算法是从相似度度量出发, 考虑物品或者用户之间的相似度进行推荐。基于内容的推荐系统

则需要建模用户偏好和物品的特征, 相比于协同过滤, 基于内容的推荐模型在推荐时会考虑物品的特征。基于协同过滤的方法容易遇到冷启动或者数据系数的问题, 而混合推荐按系统可以利用基于内容的推荐系统中的用户与物品信息来缓解协同过滤算法的这一问题。知识图谱可以用来表示实体之间的关系, 如推荐系统中物品与物品、用户与物品、用户与用户之间的关系。这些关系信息可以表示用户偏好与物品相似度等信息, 将这些信息引入推荐系统中可以显著缓解推荐系统面临的冷启动与数据稀疏问题。近期出现了一大批研究如何利用知识图谱提升推荐系统性能的工作。从模型结构角度来看, 知识图谱与推荐系统的结合有三种形式: 依次

训练、联合训练、交替训练，下文将对这三种结合形式下的主要工作进行综述。

2 依次训练

2.1 依次训练的概念

依次训练指的是知识图谱首先通过 embedding 得到实体与关系向量，然后引入推荐系统学习用户向量与物品向量，进行模型训练。知识图谱的 embedding 与推荐系统的训练是依次进行的。依次训练的代表方法为 Deep Knowledge-aware Network (DKN)。DKN 针对的是新闻推荐问题，以往的新闻推荐系统仅从新闻文本的语义表示方面进行学习，没有考虑新闻之间在知识层面的联系。而这种联系包含了用户的偏好或者新闻之间的相似度的信息，可以用来帮助推荐系统更准确的推荐用户感兴趣的新闻。

2.2 模型介绍

模型的整体架构如图 1 所示，输出包括候选新闻与用户的历史点击行为。首先通过知识蒸馏的方法，提取出新闻的标题文本的实体的向量与词向量。在获得了标题中的单体与对应的实体向量之后，为了减少 embedding 过程中的信息损失，利用了一个实体的上下文实体来表示该单词，将原实体向量与实体的上下文向量映射到一个空间里，得到映射的向量之后，作为标题单词向量的扩充，然后用 KCNN 进行处理。对于处理之后的待选新闻表示，与用户历史点击新闻表示，作者对每一篇历史点击的新闻标题表示与待选新闻表示之间进行了 attention 操作，根据注意力权重对历史点击新闻表示进行加权平均。最终将历史点击新闻表示与待选新闻表示进行拼接，最后在通过一个深度神经网络输出点击率。

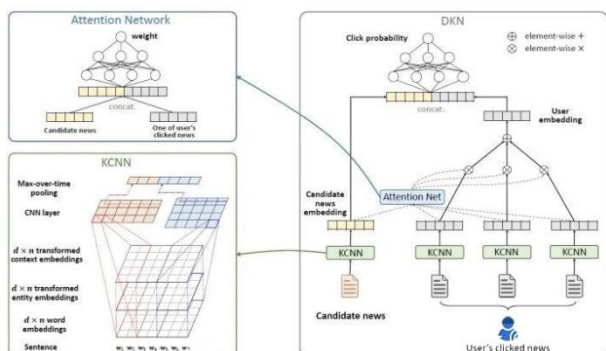


图 1 DKN 模型示意图

3 联合训练

3.1 联合训练的概念

联合训练指的是同时进行知识图谱的 embedding 与模型的训练。这里介绍的联合训练的方法为 RippleNet。RippleNet 的输入包括用户 U 与物品 V 的表示，以及用户与物品之间的交互关系目标是根据已有的信息构建知识图谱，预测一对没发生过交互的用户与物品之间发生交互的概率，也即点击率。在 RippleNet 的论文中将基于知识图谱的推荐系统分为了两类：基于嵌入的方法和基于路径的方法。其中基于嵌入的方法指的是将通过知识图谱学习到的实体与关系表示直接嵌入原先的实体向量用于推荐系统训练。而基于路径的方法则通过挖掘知识图谱中用户与物品间的各种关联模式来提供辅助信息，在这里的图是异质图，关联模式是 meta-path。异质图可以理解为，图中的节点的类别或关系的类别有不只一类；meta-path 指的是图中的一段路径，在异质图中两个节点间可能有多条潜在的 meta-path，这种基于路径的信息能够更加直观的描述知识图谱中的信息，但是 meta-path 需要手工设计。

3.2 模型介绍

整体模型如图 2 所示。Ripple 意为波纹，正如模型所示，输入用户的点击历史作为“波纹”的中心，在每一次迭代时将波纹扩展开来得到新一层的“波纹”集合（不包括之前的“波纹”），随着“波纹”的扩散，用户对新的“波纹”集合中的内容的偏好也会减弱，用户对新得到的“波纹”集合。输入物品的 embedding 表示，基于应用场景可以选择不同的表示，将物品的表示与此时的波纹集合进行关联，然后通过此概率对尾实体（新的“波纹”）进行加权，从而完成了一次 RippleNet 在图上的一次传播。对每次传播所得到的加权向量都进行求和得出一个最终的用户偏好向量，将此向量与物品表示进行叉积，预测最终的点击率。




图 2 RippleNet 模型示意图

相比于传统的基于 mta-path 的方法, RippleNet 可以根据关联概率来自动的挖掘可能的解释路径, 避免了手动设计 meta-path。一个可以预见的问题是, 随着“波纹”的传播,“波纹”集合可能变得很大, 可能会影响模型发现用户的潜在兴趣, 文中没有提出直接解决这一问题的方法, 但是讨论这种现象的一个潜在好处: 用户可能有多个路径来到达同一实体, 这些并行路径可以增加模型中用户对重叠的实体的兴趣, 类似于真实物理世界中波的合成。

4 交替训练

4.1 交替训练的概念

交替训练任务中, 对知识图谱的特征学习任务 and 模型的点击率预测任务交替进行训练。这方面的工作有 MKR。MKR 的问题定义与 RippleNet 的问题定义相同, 且所需背景知识前文都已涉及。但是 MKR 的模型结构非常新颖, 下面我们直接开始介绍 MKR 的模型。

4.2 模型介绍

与其他结合了知识图谱的推荐系统模型不同, 如图四所示, MKR 包含知识图谱编码模型、推荐模型、交叉压缩模型这三部分。知识图谱编码部分按照常规的做法, 输入知识三元组来有监督的学习尾部表示。推荐模型部分输入用户和物品的表示, 最终预测用户对物品的点击率。MKR 模型的重点在于交叉压缩模型部分, 即图 3 的 C 部分。




图3 MKR 模型示意图

交叉压缩模型的结构如图 4 所示, 将知识图谱边编码模型的头节点与推荐模型的物品编码作为输入。首先, 将两个向量相乘得到交叉向量, 认为交叉向量包含了二者之间所有可能的交互。然后, 将矩阵乘以参数向量进行压缩, 重新得到维度与交叉压缩模型的输入向量维度相同的输出向量, 从而

完成了一次前向传播。

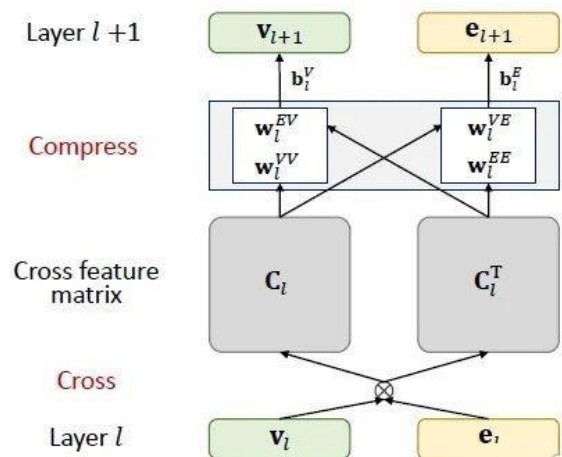


图4 交叉压缩模型示意图

文中认为, 交叉压缩模型应该只存在于网络的底层, 因为交叉压缩模型是一个信息融合的过程, 在网络的深层, 特征已经逐渐变得具体, 使得信息发生有效融合的可能性降低。

5 总结

本文从模型结构角度, 介绍了利用知识图谱增强推荐系统性能的三种方法。在深度学习时代, 除开模型大小、数据量、算力等偏硬件的因素, 决定模型性能的主要因素就在于模型结构的设计。从早些年卷积神经网络, 循环神经网络及其改版, 到近几年的对抗生成网络, transformer、attention, 都表明巧妙的模型(网络)结构设计能带来意料之外的效果。

参考文献

- [1] To reward and beyond: Analyzing the effect of reward-based strategies in aMOOC[J]. Alejandro Ortega-Arranz, Miguel L. Bote-Lorenzo, Juan I. Asensio-Pérez, Alejandra Martínez-Monés, Eduardo Gómez-Sánchez, Yannis Dimitriadis. Computers & Education. 2019 (C)
- [2] A Learning Analytics Methodology for Understanding Social Interactions in MOOCs[J]. Moreno Marcos Pedro Manuel, Alario Hoyos Carlos, Muñoz Merino Pedro J., Estevez Ayres Iria, Kloos Carlos Delgado. IEEE Transactions on Learning Technologies. 2019 (4)
- [3] Cloud Computing for Education: A Systematic Mapping Study.[J]. Maria Teresa Baldassarre, Danilo Caivano, Giovanni Dimauro, Enrica Gentile, Giuseppe Visaggio. IEEE Trans. Education. 2018 (3)

- [4]Sound and Music Recommendation with Knowledge Graphs[J] . Sergio Oramas,Vito Claudio Ostuni,Tommaso Di Noia,Xavier Serra,Eugenio Di Sciascio. ACM Transactions on Intelligent Systems and Techn . 2016 (2)
- [5]E-Learning personalization based on hybrid recommendation strategyand learning style identification[J] . Zoran Budimac. Computers &Education . 2010 (3)
- [6]Cognitive Diagnosis and Q-Matrices in Language Assessment[J] . Yong-Won Lee,Yasuyo Sawaki. Language Assessment Quarterly . 2009 (3)
- [7]DBpedia - A crystallization point for the Web of Data[J] . Christian Bizer,JensLehmann,GeorgiKobilarov,S?renAuer,ChristianBecker,Richard Cyganiak,Sebastian Hellmann. Web Semantics: Science, Services and Agents on the World Wide Web . 2009 (3)
- [8]DINA Model and Parameter Estimation: A Didactic[J] . de la Torre Jimmy. Journal of Educational and Behavioral Statistics . 2009 (1)